2026 第九届传智杯全国大学生数智创新与 AI 应用大赛

HybridMind

端云协同的自适应大模型路由：用「本地答对概率」决定一次推理该花多少钱

赛道　AI 大模型创新应用挑战赛（技术应用赛 · 个人赛）

组别　B 组（普通本科）

参赛者　张云迪

所在院校　商洛学院

提交日期　2026 年 10 月

在线演示：https://hanyue0-hybridmind.ms.show

代码仓库：https://github.com/hanyue0/hybridmind

摘 要

把大模型应用部署到普通人的电脑上，会立刻遇到一组互相冲突的约束：云端大模型答得准、响应快，但每次调用都要付费、要联网、数据要离开本机；本地小模型零边际成本、数据不出设备、断网可用，却会在稍微复杂的问题上出错。本文提出 HybridMind，一个端云协同的推理路由框架：它在每次请求到达时预测「本地模型能否答对这道题」，判得准则留在本地，判不准才升级云端，并把这个决策连同理由、耗时与费用一并呈现给使用者。

与常见的「按题目难度分流」不同，本文的关键判断是：字符串规则描述的是"题目怎么写"，而不是"模型会不会做错"。我们先用可解释的题面规则建立基线，再用本地模型的真实作答结果作为标签训练学习型路由器，并在同一套封闭答案评测集上比较两者。在 160 条自建题目上，规则路由与学习型路由在训练分布内几乎打平（云端占比 57% 对 56%，准确率同为 91.9%）；但换到 40 条全新句式的分布外题目后，规则路由的难度分从均值 0.33 塌到 0.14（特征词表全部未命中），路由形同虚设、准确率停留在全本地的 75.0%，而学习型路由在同等云端预算下达到 87.5%–90.0%，30% 预算时领先 12.5 个百分点，甚至超过纯云端方案（87.5%）。

本文还报告了一个与直觉相反、但对工程实践有直接意义的实测结论：在这台无独立显卡、单通道内存的普通笔记本上，云端在准确率与延迟上都优于本地（92.5% 对 60.0%，753 ms 对 6271 ms），而每千次调用仅需 ¥0.19。因此路由的价值并不在"省钱"，而在隐私、离线可用性与规模化成本——这一点若不在文档里说清，整个方案就会建立在一个站不住的前提上。

系统以 Python 实现，本地推理走 Ollama（Qwen2.5-1.5B，Q4 量化），云端走任意 OpenAI 兼容接口，前端零依赖、支持 Server-Sent Events 逐 token 输出与路由决策可视化。全部实验基于封闭答案评测集与自动判分，判分不使用大模型当裁判，任何人可用仓库内脚本逐条复算。

关键词：端云协同；大模型路由；成本优化；模型级联；分布外泛化；可解释决策

目 录

1 问题与动机 5

1.1 端侧推理为何再次成为焦点 5

1.2 一个被误判的前提 5

1.3 本文要回答的三个问题 5

1.4 主要贡献 6

2 相关工作 7

2.1 模型级联与预算感知推理 7

2.2 大模型路由 7

2.3 端侧小模型 7

2.4 与本文的差异 8

3 系统设计 9

3.1 总体架构 9

3.2 推理后端抽象 9

3.3 编排与降级 9

3.4 可观测性与成本账本 10

3.5 交互与可视化 10

4 路由方法 11

4.1 问题形式化 11

4.2 规则基线 11

4.3 学习型路由 12

4.4 置信度兜底与触发条件 12

5 实验设置 14

5.1 评测集构造 14

5.2 判分口径 14

5.3 对照与指标 14

5.4 硬件与超参 15

6 结果与分析 16

6.1 本机推理能力 16

6.2 全本地与全云端基线 16

6.3 路由质量 17

6.4 分布外检验 18

6.5 失败分析 20

7 讨论 21

7.1 为什么"省钱"不是好理由 21

7.2 阈值的业务含义 21

7.3 局限性 21

7.4 改进方向 22

8 工程实现与复现 23

8.1 代码结构 23

8.2 部署 23

8.3 复现步骤 24

8.4 开发过程留痕 24

参考文献 25

1　问题与动机

1.1 端侧推理为何再次成为焦点

2025 年以来，大模型的竞争重心从「参数规模」转向「单位成本下的可用性」。一方面，Qwen2.5、Phi、Gemma 等开源小模型在 0.5B – 3B 量级上已能稳定完成指令跟随、抽取与简单推理；另一方面，消费级设备的算力与内存普遍停留在 8 – 16 GB，无法承载 7B 以上的模型。边缘计算方向的系统性综述指出，端侧部署的核心矛盾在于「在严格的内存与算力预算下保持多步推理能力」，而弹性卸载与云端协同正是缓解这一矛盾的主要手段[1]。于是出现了一个现实的工程问题：当一个应用既要覆盖简单请求、又要处理复杂请求时，应该把哪些请求放在本地？

这不是一个纯学术问题。对一个面向个人用户的应用，云端调用意味着三件事同时发生：账单随调用量线性增长、响应时间多一次网络往返、用户数据离开设备。而对一个面向企业内网的应用，第三点往往是硬约束——数据不出内网，本地模型就是唯一选项，哪怕它更笨。路由层因此成为端云协同的枢纽：它决定了成本、隐私与质量三者的实际分配比例。

1.2 一个被误判的前提

本文最初的设计建立在一条看似显然的推理上：本地推理零成本、延迟更低，所以把简单请求留在本地就能同时省钱和提速。为了验证它，我们在开发机上做了一次完整的双端评测：本地 Qwen2.5-1.5B（Q4 量化，986 MB）与云端 deepseek-chat，在 160 条同一评测集上运行。

结果与预期相反（见表 6-2）：云端不仅准确率高 32.5 个百分点，平均延迟还低到 1/8，而每千次调用的费用只有 ¥0.19。原因并不神秘——开发机没有独立显卡，内存为单通道 DDR4-3200，本地推理速度被带宽压在 3 – 4 token/s；而云端单次往返加生成不到 1 秒。

> 这个结果推翻了我们自己的立论。如果照原计划把"省钱的毫秒级端侧推理"写进文档，作品在答辩时会被一个反问击穿：一千次才两毛钱，你省这钱意义何在？因此本文在第 1.3 节重构了问题，并在第 7.1 节正面回答"那为什么还要路由"。

这次失败带来一个方法论上的收获：端侧推理的价值必须按场景拆开谈，而不能笼统地宣称"更快更省"。在隐私敏感、网络受限、调用规模巨大的场景里，本地路由的价值是真实且不可替代的；在单机、单用户、低调用量的场景里，它的价值接近于零。诚实地区分这两种情形，比给出一个漂亮的平均数字更重要。

1.3 本文要回答的三个问题

据此，本文将研究问题收敛为三个可被实验检验的具体问题：

1. Q1（能力边界）：本地小模型在什么类型的题目上可靠？这个边界能否被量化？
2. Q2（路由方法）：预测「本地能否答对」这件事，可解释的题面规则与基于真实作答标签的学习模型，哪一个更可靠？在什么条件下？

3. Q3（代价结构）：引入路由之后，准确率、成本、延迟各自付出或节省了多少？这个权衡的边界在哪里？

Q2 是本文的重点。我们在实验中发现了一个容易被忽略的陷阱：在训练分布内比较两种路由方法，会得出完全错误的结论。规则路由的特征词表与评测集的生成模板同源，因此在训练集上表现优异；一旦题目换一种说法，它就彻底失效。这个现象在后文第 6.4 节以分布外实验的形式被量化。

1.4 主要贡献

1. 一个可落地的端云协同路由框架：两种推理后端同构抽象、动态降级、逐请求成本账本、流式输出与决策可视化，在无 GPU 的普通笔记本上可完整运行（第 3 章）。
2. 规则与学习两种路由的系统对比：以本地模型真实作答为标签训练路由器（5 折交叉验证 AUC 0.9355），并在训练分布内与分布外两个维度上比较（第 4、6 章）。
3. 一个诚实的方法论结论：规则路由学到的是"题目的写法"，学习型路由学到的是"模型的能力边界"；前者在分布外会静默失效，且失效时不会报错，只会把难题全部留在本地（第 6.4 节）。
4. 一套可复算的评测方法：封闭答案评测集 + 不依赖大模型裁判的自动判分 + oracle 上界 + 等预算曲线，所有数字均可用仓库脚本一键重跑（第 5 章、第 8 章）。

2 相关工作

2.1 模型级联与预算感知推理

用便宜模型处理简单请求、贵模型兜底难请求，这一思路在文献中通常称为模型级联（cascade）。FrugalGPT 系统化地研究了级联的三种省钱手段——提示词压缩、答案缓存与级联调用，并在多个数据集上报告了「同等准确率下成本降低一个数量级」的结果[2]。这类工作的共同前提是：存在一个可靠的质量信号，能判断便宜模型的输出是否可接受。FrugalGPT 的做法是用一个打分器或规则阈值；本文则把这个信号建模为「本地答对概率」，并直接用真实作答结果训练它。

与级联相邻的另一个概念是混合专家（MoE）中的路由：门控网络在层内决定激活哪些专家[3]。本文的"路由"发生在系统层而非模型层，选择的是推理后端而非神经元子集，因此两者在实现与优化目标上都不同——MoE 优化的是模型容量与计算量的比，本文优化的是应用侧的准确率、成本与隐私的分配。

更系统的梳理见 Varangot-Reille 等人的综述[4]：该文把路由形式化为「性能—成本」优化问题，按"何时路由、路由到什么、如何实现"三个维度归纳了相似度匹配、监督学习、强化学习与生成式四类方法，并指出当前研究的主要短板是实验缺乏标准化、以及很少考虑非财务成本。本文的规则基线对应其中"规则/相似度"一档，学习型路由对应"监督学习"一档，两者在同一评测集上的对照，正是对该综述所呼吁的"可比较实验"的一次小规模响应。

2.2 大模型路由

RouteLLM 将路由形式化为二分类问题：用偏好数据训练一个分类器，预测「强模型是否显著优于弱模型」，从而在调用前决定去向[5]。它在 MT-Bench、MMLU 等公开基准上验证了"用 20%–50% 的强模型调用量保留 95% 以上的质量"。本文与它的差别有三点：其一，本文的判断对象是本地小模型是否会答错，标签直接来自真实作答而非人类偏好；其二，本文关注的是单机、消费级硬件这一受限场景，特征必须能在毫秒内算出、且不依赖额外模型；其三，本文额外检验了分布外泛化，而这一点在多数路由工作报告中并未单独评估。

2.3 端侧小模型

Qwen2.5 系列在 0.5B–72B 的多个规模上开源，其 1.5B 版本在指令跟随与中文任务上具备基本可用性，且 4-bit 量化后模型体积约 1 GB，可放入普通笔记本内存[6]。这为"在消费级设备上跑本地推理"提供了现实基础。但也要看到：小模型的失败模式往往是静默的——它不会说"我不会"，而是给出一个语法通顺但数值错误的答案。这使"事后检测错误"比"事前预测错误"更难，也是本文选择在调用前做判断的原因之一。

近来的工作进一步把"大小模型如何配合"推进到 token 粒度。R2R 的观察是：大模型与小模型的推理路径只有少数关键 token 会真正分叉，其余 token 要么相同、要么只是表述差异；因此只需在这些分叉点上调用大模型[7]。这类方法能在同等平均激活参数下逼近大模型效果，但需要模型白盒访问与专门的训练

管线。本文工作在请求级路由，粒度更粗、效果上限更低，代价是它可以跨厂商、跨部署形态直接落地——两者的关系类似"编译期优化"与"运行时调度"。

2.4 与本文的差异

维度	FrugalGPT / 级联	RouteLLM	本文
判断对象	输出是否达标	强模型是否更好	本地是否会答错
标签来源	打分器 / 规则	人类偏好	真实作答结果
特征开销	低	需嵌入模型	纯题面统计，零模型
部署环境	云端	云端	单机笔记本科普及
分布外评估	未单独报告	未单独报告	专门构造并报告

表 2-1　本文与代表性路由工作的差异

3　系统设计

3.1 总体架构

系统分为四层，自下而上分别是推理后端、路由决策、编排与账本、交互呈现。分层的目的是让每一层都能被单独替换与单独测量：换模型不动路由，换路由不动编排，换界面不动业务。



图 3-1　四层架构。同层内两个后端对上层完全同构，因此路由切换对编排层透明。

3.2 推理后端抽象

两个后端实现同一个协议：`generate(messages, max_tokens, temperature) -> Generation`，其中 `Generation` 携带文本、token 数、延迟与费用。这段抽象是整个系统的关键——正因为本地与云端返回同一种结构，编排层才不需要知道这次推理究竟发生在哪里，成本账本也才能用同一套代码统计两种后端。

```
@dataclass
class Generation:
    text: str
    model: str
    prompt_tokens: int
    completion_tokens: int
    latency_ms: float
    cost_cny: float = 0.0     # 本地恒为 0，云端按价格表计算
```

云端价格表以「元 / 百万 token」为单位内置在配置里，费用由 token 数与单价直接相乘得到，不使用估算值：

```
cost = (prompt_tokens * price.input + completion_tokens * price.output) / 1e6
```

3.3 编排与降级

编排层负责一次请求的完整生命周期，共四步：

1. 决策：调用路由层得到 `route ∈ {local, cloud}` 与人类可读的理由列表；

2. 推理：调用对应后端；若抛出 `ProviderError`（网络中断、密钥失效、服务超时），自动切到另一端并在理由中记录；
3. 兜底：若本次走的是本地且处于"不确信"区间，让本地模型自评置信度，低于阈值则升级云端重答（详见 4.4）；
4. 记账：把本次的路由、token、费用、延迟写入进程内账本。

降级不是可选项而是必需项：开发过程中我们遇到过一次 DeepSeek 返回 429 的情况，若不降级，整个演示会直接报错中断。降级后用户看到的仍然是一个答案，只是在路由面板上多一行「云端失败，已降级本地」——失败可见但不致命，这是可运营系统的底线。

3.4 可观测性与成本账本

每一次请求都会产出一条完整的"路由凭证"（`RouteTrace`），它是这套系统能自证价值的基础。字段包括：走了哪条路、分值多少、阈值多少、决策理由、是否发生升级、本地自评置信度、端到端延迟、输入输出 token 与费用。

账本（`Ledger`）在进程内累计请求数、本地占比、云端调用数、升级次数、累计费用与平均延迟，前端底部状态栏实时展示。这个设计让"路由到底省了多少"成为屏幕上持续可见的数字，而不是文档里一个跑完就忘的百分比。

3.5 交互与可视化

界面刻意做成左右两栏：左侧对话，右侧"路由决策"。右侧面板是本文的表达重点，它需要在一屏内回答四个问题——走了哪条路、凭什么这么判、花了多少钱、等了多久。

- 顶部色块：绿色 = 本地，蓝色 = 云端，发生升级时标注"已升级"；
- 数值条：显示当前策略的分值与其阈值刻度线，阈值在条上的位置直观展示了"离边界多远"；
- 理由列表：由特征名直接拼成的自然语言，例如「预测本地答对概率 0.55 < 阈值 0.85 → cloud」，下一行附「参考难度分 0.20（规则视角）」，让两种策略的判断可以并排比较；
- 指标格：延迟、费用、输入/输出 token、自评置信度。

因为本地推理在开发机上只有 3–4 token/s，界面必须支持流式输出：采用 Server-Sent Events 逐 token 推送，事件类型包括 `trace`（决策先于生成下发）、`delta`（增量文本）、`status`（自评中）、`escalate`（升级提示）、`reset`（清空重写）、`done`（完整凭证）。把"决策"放在"第一个字"之前下发，是为了让用户在实际等待生成时就已经知道这次推理去了哪里。

4　路由方法

4.1 问题形式化

设一次请求的输入文本为 x，本地后端为 M_L，云端为 M_C。定义二元变量 y 表示"本地是否答对"（以评测集的标准答案判定）。路由器的任务是学习一个打分函数 $s(x) \in [0,1]$，并选择阈值 t：当 $s(x) \geq t$ 时走本地，否则走云端。

在给定云端预算 B（允许上云的请求比例）下，目标是最大化端到端准确率：

```
max  E[ correct ]  s.t.  P( route = cloud ) ≤ B
```

这个形式化区分了两种策略的本质差异：规则策略的 s 是"难度分"（越高越该上云，方向相反），学习型策略的 s 直接就是"本地答对概率"的估计。前者是人工先验，后者是数据驱动的估计量——这正是第 6.4 节分布外实验要检验的差别。

4.2 规则基线

基线使用显式字符串特征，不依赖任何模型，目的是提供一个"零成本、完全可解释"的参照。特征分为五组：数学领域术语、应用题语境词、推理要求词、代码/算法词、并列与条件结构词，再叠加文本长度、问句数量与算式模式。特征的加权和经截断后得到 [0,1] 的难度分。

设计时刻意做过一次修正。初版把「计算」「多少」也算作数学特征，结果「计算 87+8 是多少」与「计算这个积分」得到同样的分数。这类词其实是问句措辞而非难度信号，必须与领域术语分开，否则所有算术题都会被送去云端，方案的成本优势直接归零。修正后的权重见表 4-1。

特征组	权重	说明
数学领域术语	0.28 + 0.05 • (k−1)	方程、积分、概率、排列组合…
推理/论证要求	0.20 + 0.08 • (k−1)	证明、推导、反证、分析…
代码/算法	0.25 + 0.05 • (k−1)	函数、报错、复杂度…
应用题语境	0.12 + 0.03 • (k−1)	单价、折扣、工程、工人…
算式表达式	0.08	出现 a+b 形式，弱信号
文本长度	0.20 • min(len/300, 1)	长度超过 75 字才计入
并列/条件结构	0.10 • min(k, 2)	然后、并且、如果…
基准分	0.10	所有请求的起点

表 4-1　规则难度分的权重配置（k 为命中次数，单组最多计入 3 次）

4.3 学习型路由

学习型路由把问题从"这题难不难"改成"本地会不会答错"。标签直接来自本地模型的真实作答结果（答对 1、答错 0），共 160 条。特征扩展到 14 维，全部是可在微秒级算出的题面统计量，不引入嵌入模型（表 4-2）。

类别	特征	动机
规模	字符长度、句数、子句数、问句数	长题往往需要多处约束同时满足
数值	数字个数、最大数值(log1p)、运算符个数、是否含百分号	多步运算与百分比链是本地模型的主要失手区
语义	数学术语、应用题语境、推理要求、代码术语、并列结构	复用规则层的词表，保证两层可对照
模式	是否含算式表达式	区分"直接算"与"读题后算"

表 4-2　学习型路由的 14 维特征

模型选用 L2 正则的逻辑回归，先做标准化。选择理由并非"效果最好"，而是样本量与可解释性：160 条样本不足以支撑复杂模型，而逻辑回归的系数可以直接读成"该特征让本地答对的几率上升还是下降"，便于答辩时逐条解释。训练流程严格使用 5 折分层交叉验证，阈值只在 out-of-fold 预测上选取，避免用训练集自身预测调参带来的乐观偏差。

训练完成后，模型被导出为 JSON（标准化均值、方差、系数、截距），运行期只用纯 Python 做一次点积与 sigmoid，不依赖 scikit-learn。导出结果与 sklearn 预测的最大偏差为 0.000000，已在训练脚本中自动校验。这样部署端少一个重型依赖，评审也更容易复现。

特征	系数	解读
`length`	−1.139	越长越可能答错
`multi_hop_terms`	−0.964	含"然后/并且"等结构显著降低本地正确率
`word_problem_terms`	−0.928	应用题语境是强负信号
`num_sentences`	−0.862	多句意味着多约束
`arithmetic`	+0.530	直接给算式的题反而更容易答对
`math_terms`	−0.431	领域术语指向需要专门知识
`log_max_number`	+0.356	数值较大时模型更谨慎，错误反而更少

表 4-3　标准化后的特征权重（正 = 倾向于本地答对）。`code_terms` 与 `reasoning_terms` 系数为 0，因为评测集中未出现此类样本，属已知局限。

4.4 置信度兜底与触发条件

除了"事前预测"，系统还有一道"事后检查"：让本地模型对自己的答案给出 0–1 的置信度，低于阈值 τ 就升级云端重答。思路借自推测执行——先让便宜的算，验证不过才付昂贵的那份。

但实测中这条机制出过一次洋相：问「1+1 等于几」时，路由判本地（本地答对概率 0.99），兜底却因为小模型自评不足而把它拖去云端，白花了一次调用。问题不在兜底本身，而在于它忽略了一个已经存在的先验。修正方案是：学习型路由下，只有当概率落在［阈值，阈值 + margin）的不确定区间时才启用自评，margin 默认 0.10。这样"很有把握的简单题"不会再被二次检查，而"擦边判给本地"的题目仍保留兜底。

> 这也解释了为什么本文不把"模型自评置信度"当作主信号。已有研究表明现代神经网络普遍存在过度自信的问题[8]，小模型尤甚；本文的实测也印证了这一点——它在「1+1」上给出的置信度低于阈值。因此自评只能作为辅助，主判据必须是来自真实作答的统计量。

5　实验设置

5.1 评测集构造

评测集共 160 条，全部为封闭答案题目，分四个难度档（表 5-1）。题目由脚本按固定随机种子程序化生成，标准答案由生成过程精确计算，因此不存在"标准答案本身有误"的风险，任何人重跑脚本都能得到同一份数据。

难度档	题目形态	样本	考察点
tier1	单步加减乘除	60	基本运算是否可靠
tier2	两步运算、折扣、周长	50	能否保持中间结果
tier3	三步运算、百分比连乘、路程	30	多步推导的稳定性
tier4	工程问题、数位运算等多步推理	20	复合约束下的推理

表 5-1　主评测集构成（n=160）

另构造 40 条分布外（OOD）题目用于泛化检验。这批题目的句式与词汇与主集刻意不重叠：找零、分组平均、反向求解、时间跨度、倍数关系、和差问题，外加 5 条常识短答。构造它们的目的只有一个——检验路由策略在"没见过的说法"上是否还成立，因此两个路由器都不在新数据上重训。

5.2 判分口径

判分刻意不使用大模型当裁判。理由有两条：其一，用模型判模型会引入一个不可控变量，且同样产生费用；其二，评委无法逐条复算，结论的可信度会打折。本文采用两条确定性规则：

- 数值题：取预测文本中最后一个数字与标准答案比较（容差 1e-6）。选"最后一个"是因为大模型的回答惯例是先写步骤、最后给结论。
- 短答题：把预测与标准答案（及其别名列表）归一化后做包含匹配，任一别名命中即判对。

判分规则在开发过程中修正过一次，值得记录。评测早期发现：「234 除以 13 的商是多少」标准答案为 18，模型答「商是 18，余数是 4」，按"取最后一个数字"会被判错——但它的商是对的，余数是题目之外的附带量。修正为：先剥离「余数/余…」从句，再取最后一个数字。同时补充了回归测试，确保这个修正不会掩盖商本身算错（「商是 20，余数是 7」对标准答案 21 仍判错）。这一处修正使 80 条子集上的准确率由 82.5% 调整为 85.0%，共 2 条改判。

5.3 对照与指标

实验设四组对照：全本地（不路由）、全云端（不路由）、规则路由（阈值 θ）、学习型路由（阈值由交叉验证选取）。此外计算一个理论上界 oracle：对每条题目都取"两个模型里能答对的那一个"，用来衡量路由还剩多少提升空间。

指标包括：端到端准确率、云端调用占比、千次调用成本（元）、平均与 P95 延迟。为了公平比较两种路由策略，本文在相同云端预算下绘制准确率曲线——把题目按各自打分排序，取最该上云的 B% 送去云端，其余留本地，这样比较的是"花同样多的钱谁更准"，而不是让两种策略各自挑选最有利的阈值。

5.4 硬件与超参

项目	配置
CPU	Intel Core i5-13420H（8 核 12 线程）
内存	16 GB DDR4-3200，单通道（仅插一条）
显卡	Intel UHD 集显，无 CUDA
系统	Windows 11 家庭版
本地模型	qwen2.5:1.5b（Q4_K_M，986 MB，Ollama 0.40.10）
云端模型	deepseek-chat（OpenAI 兼容接口）
生成参数	temperature 0.2，max_tokens 128（评测）/ 256（演示）
学习型模型	标准化 + L2 逻辑回归（C=1.0，class_weight=balanced），5 折分层交叉验证，随机种子 20261024

表 5-2　实验环境与超参

6　结果与分析

6.1 本机推理能力

先回答 Q1 的一半：本地模型在这台机器上到底能跑多快。用三条典型提示做基准，模型已预热（排除首次加载开销）：

提示类型	输出 token	延迟	吞吐
单步运算	13	10.1 s	1.3 tok/s
两步应用题	103	23.9 s	4.3 tok/s
证明类长回答	256	62.9 s	4.1 tok/s

表 6-1　本机推理基准（qwen2.5:1.5b，Q4_K_M，纯 CPU）

稳定态吞吐为 3.2 – 4.1 token/s。这个数字远低于同类硬件的常见报告值（15 – 25 token/s），我们做了归因排查：

- `ollama ps` 显示 100% CPU、无 GPU 卸载，排除集显拖累；
- 线程数从 4 试到 12，吞吐仅从 2.4 升到 3.1 token/s，说明瓶颈不在算力；
- 电源计划由"平衡"切到"高性能"，无明显改善，说明不是降频；
- `Win32_PhysicalMemory` 显示只插了一条 16 GB 内存。

大模型自回归解码每生成一个 token 都要把权重完整过一遍，属典型的内存带宽受限任务。单通道 DDR4-3200 的有效带宽约为双通道的一半，正是这个数量级的差距。这也解释了一个反直觉现象：增加算力收益有限，增加内存通道收益明显。

6.2 全本地与全云端基线

同一评测集、同一判分口径下，两个极端策略的对比（表 6-2）。这是全文最重要的一张表，因为它决定了后续所有讨论的前提。

指标	全本地	全云端
准确率	60.0%	92.5%
单条成本	¥0	¥0.000194
千次成本	¥0	¥0.194
平均延迟	6271 ms	753 ms
P95 延迟	16263 ms	1012 ms

表 6-2　两个极端策略的端到端表现（n=160）

按难度档拆开看，本地模型的失效边界非常清晰：

难度档	样本	本地准确率	典型失败
tier1 单步	60	98.3%	几乎无
tier2 两步	50	68.0%	33×7+11 答成 260
tier3 三步	30	10.0%	百分比连乘几乎全错
tier4 多步推理	20	0%	工程问题全部失手

表 6-3　本地准确率随难度单调崩塌

这是本作品最干净的一个实验结果：1.5B 模型在单步算术上接近满分，一旦需要保持中间结果就断崖式下跌。这条曲线不需要任何解释性话术——它本身就说明了"为什么需要路由"：不是所有请求都值得送去云端，但两步以上必须送。

6.3 路由质量

6.3.1 规则路由：能分，但分不细

在 θ=0.45（初始默认值）下，160 条中只有 1 条被判给云端，路由形同虚设。把阈值下调到 0.20 才有实际效果：云端占比 57%，准确率 91.9%，千次成本 ¥0.134，相比纯云端准确率只降 0.6 个百分点、成本降 31%。阈值扫描结果见表 6-4。

θ	云端占比	准确率	千次成本
0.00	100%	92.5%	¥0.194
0.20	57%	91.9%	¥0.134
0.30	16%	76.2%	¥0.043
0.40	1%	60.6%	¥0.001
0.45（原默认）	1%	60.6%	¥0.001

表 6-4　规则路由的阈值扫描（离线模拟，零成本）

注意 θ 从 0.20 到 0.30 时准确率从 91.9% 猛跌到 76.2%——曲线是断崖而非平滑。原因是规则特征只能把题目粗略分堆，阈值一旦收紧就整档丢失。

6.3.2 学习型路由：分布内打平

学习型路由的 5 折交叉验证 AUC = 0.9355，说明特征确实携带了"本地是否会答错"的信息。但在训练分布内，它的端到端表现与规则路由几乎相同（云端 56%、准确率 91.9%），并未带来可观测的收益（图 6-1 蓝线与橙线大段重合）。

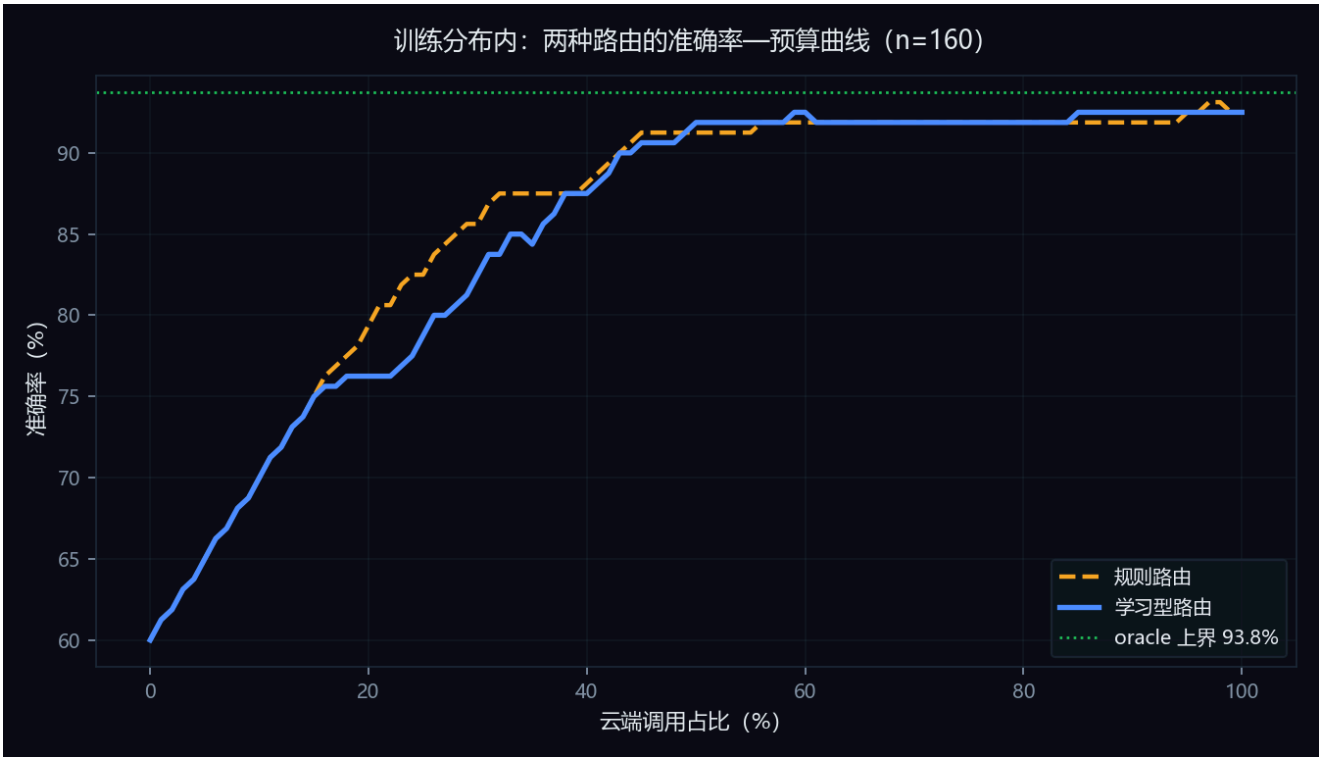


图 6-1　训练分布内两种路由的准确率—预算曲线（n=160）。橙线在 15%–40% 预算区反而更高。

如果实验到此为止，结论会是"学习型路由没有必要"。这个结论是错的，原因在第 6.4 节。

6.4 分布外检验

我们另外构造 40 条全新句式的题目，两个路由器都不在新数据上重训，直接沿用主集训练/调参的结果。结果如表 6-5 与图 6-2。

策略	云端占比	OOD 准确率
全本地	0%	75.0%
全云端	100%	87.5%
规则路由 θ=0.20	32%	75.0%
学习型路由 $p<0.85$	68%	90.0%

表 6-5　分布外检验（n=40，均未重训）

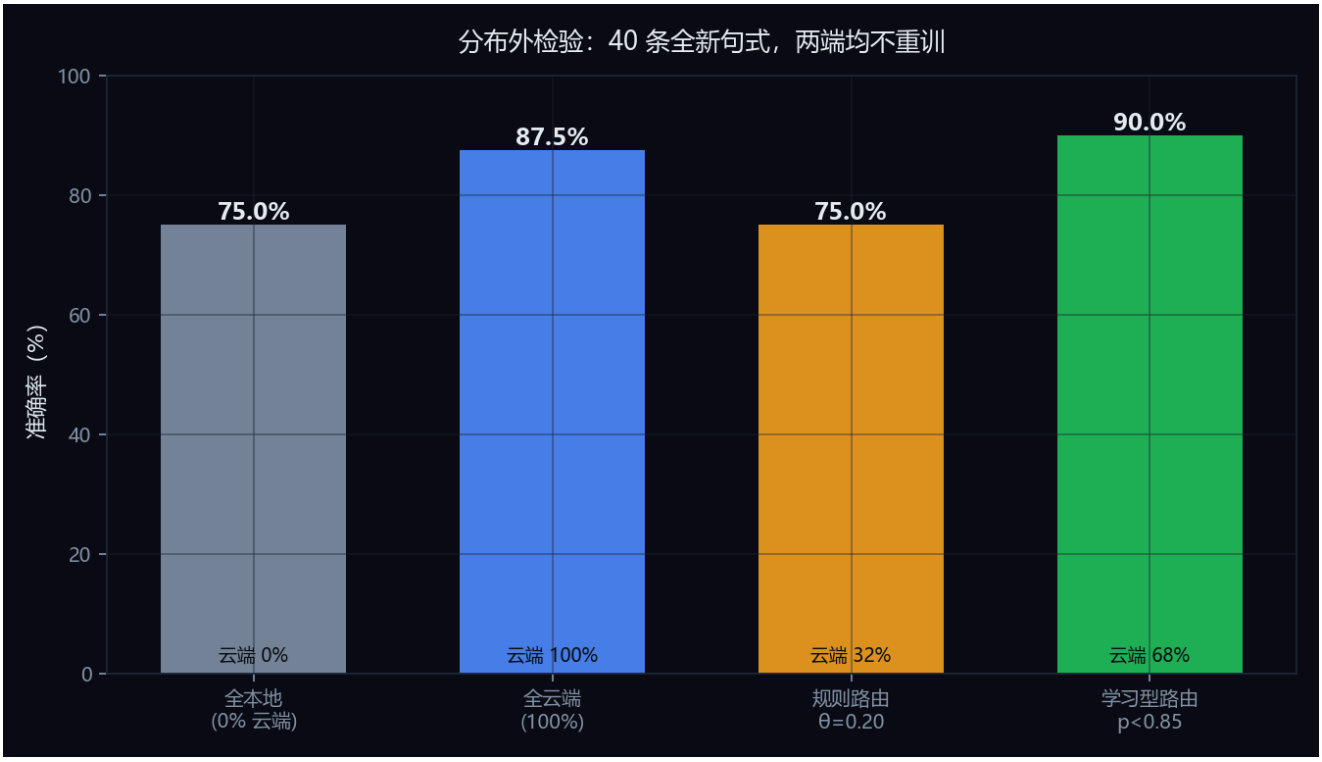


图 6-2　分布外检验：规则路由的准确率与"完全不做路由"相同，学习型路由甚至超过纯云端。

同等云端预算下的逐点比较更能说明问题：

云端预算	规则路由	学习型路由	差距
20%	75.0%	77.5%	+2.5 pt
30%	75.0%	87.5%	+12.5 pt
40%	72.5%	87.5%	+15.0 pt
50%	75.0%	87.5%	+12.5 pt
60%	85.0%	87.5%	+2.5 pt

表 6-6　同预算下两种路由的 OOD 准确率

为什么规则路由会失效

诊断结果非常直接：规则难度分在 OOD 上均值从 0.33 塌到 0.14，最大值只有 0.22。它的特征词表是「计算 / 求解 / 多少 / 单价 / 折扣」，而 OOD 题目说的是「还剩几元 / 每组几人 / 这个数是几」——一个词都没命中。于是所有题都被判为简单，全部留在本地。

> 最危险的地方在于它不会报错。规则路由失效时没有任何异常：服务正常、延迟正常、费用为零，只有准确率悄悄退回到"完全不做路由"的水平。如果这套系统上线运营，这种失效可能几个月都不会被发现。

学习型路由学到的是「什么样的题本地会答错」这一更本质的映射，因此能跨表述泛化。特别值得注意的是它在 OOD 上达到 90.0%，超过了纯云端方案的 87.5%——说明它不仅能"少花钱"，还能"挑对模

型″：有些题本地答对了而云端答错，路由把这些题留在了本地。

作为参照，主评测集上的 oracle 上界为 93.8%——即″每条都挑会做的那个模型″也只有这个水平，因为其中有 10/160 条是本地与云端都答错的。这个数字给出了路由的收益天花板：它决定了继续优化路由最多还能换来 1.3 个百分点，也说明云端模型本身已接近该评测集的能力上限，后续的提升空间更可能来自题目分布而非调度策略。

6.5 失败分析

诚实记录三类失败，它们比成功案例更能说明系统的边界。

其一，本地算错但表述通顺。「先算 33 乘以 7，再加上 11」标准答案 242，模型答 260，且给出了一行看似合理的算式。这类错误无法从文本形式上识别，只能靠统计特征事前预判。

其二，规则路由的特征盲区。「一个班 45 人，把男生平均分成 5 组，每组几人」不含任何难度词，规则给的难度分约 0.12，必然留在本地；而这类题需要先做减法再做除法，本地约有一半概率出错。

其三，自评置信度的不稳定性。在「1+1」这类题目上，本地模型自评置信度低于阈值 τ，触发了一次不必要的升级。这说明模型自评不是一个可靠的校准器，只能作为辅助信号——这也是 4.4 节把兜底限制在不确定区间的原因。

7 讨论

7.1 为什么"省钱"不是好理由

按表 6-2，云端千次调用仅 ¥0.194。假设一个应用每天 1 万次请求，全部走云端每月约 ¥58——这个量级上，"路由省钱"几乎没有商业意义。因此把省钱的毫秒级端侧推理当作作品卖点是危险的。

但把量级放大三个数量级，结论就变了：

日请求量	全云端月成本	路由 50% 本地后
1 万	¥58	¥29
100 万	¥5,800	¥2,900
1 亿	¥58 万	¥29 万

表 7-1　不同量级下的成本结构（按 ¥0.194/千次折算）

真正让本地路由不可替代的是另外三件事，它们都不随规模线性衰减：

- 隐私：被判为简单的请求根本不出设备。对医疗、法务、内部知识库场景，这不是省钱问题而是合规问题。
- 可用性：断网、限流、密钥失效、服务商故障时，本地分支仍能服务。系统的降级路径在设计时就是按"云端一定可能挂"来写的。
- 响应确定性：云端延迟受网络与队列影响，P95 可能突然劣化；本地延迟只受本机负载影响，波动可预测。

7.2 阈值的业务含义

学习型路由的阈值有一个直接的业务解释：它就是你愿意接受的"本地答错率"水位。阈值 0.85 意味着"只有预测本地答对概率高于 85% 才留在本地"，低于这个把握就花钱上云。

这比规则路由的"难度分 0.45"好沟通得多——后者需要解释一堆特征权重，前者只需要问一句"你愿意用多少准确率换多少成本"。在真实产品中，这个阈值应当由业务方按场景设定：客服场景可以设 0.9（宁可多花钱），个人助手可以设 0.7（省钱优先）。

7.3 局限性

1. 样本量偏小：主集 160 条、OOD 40 条，AUC 的置信区间较宽，未做 bootstrap 估计。
2. OOD 集由作者设计：存在设计者偏差的可能。不过失效机制（特征词未命中）是透明且可逐条复核的，不依赖主观判断。
3. 阈值未在 OOD 上二次校准：直接沿用了主集选择的 0.85，这对学习型路由略保守（云端占比 68%）。

4. 单轮对话：特征只取当前问题，不含对话历史。多轮场景下"上文是否已给出关键约束"会显著影响本地成功率。
5. 单机单模型：只验证了一种本地模型规格，未覆盖 0.5B / 3B 或换用其他硬件时的表现差异。
6. 特征覆盖不全：`code_terms` 与 `reasoning_terms` 在评测集中未出现，系数为 0，等于这两个特征未被检验。

7.4 改进方向

1. 扩充真实流量样本：从公开问答集采样并人工标注难度，替代程序化生成的题目，检验结论是否成立。
2. 引入对话状态特征：把轮次、上文长度、是否重复提问纳入特征，覆盖多轮场景。
3. 按硬件自适应阈值：启动时测一次本地吞吐，据此调整 θ 或 p 的阈值——换台好机器自动放宽本地配额。
4. 在线学习：把每次真实请求的对错回流为标签，周期性增量更新路由器，缓解分布漂移。
5. 多档路由：目前是二分类（本地/云端），可扩展为"本地小模型 / 本地大模型 / 云端"三档。

8 工程实现与复现

8.1 代码结构

```
app/
  config.py           全部可调参数（阈值、价格表、预算）
  schemas.py          请求/响应/路由凭证的数据结构
  pipeline.py         编排：决策 → 推理 → 兜底 → 记账（含流式）
  providers/          本地(Ollama) / 云端(OpenAI 兼容) 同构适配
  router/             特征、策略、分类器、置信度
  eval/               判分口径、评测执行、结果落盘
  web/                FastAPI + 零依赖前端
scripts/
  gen_eval_set.py     评测集生成（固定种子，可复现）
  gen_ood_set.py      分布外评测集生成
  train_router.py     路由器训练 + 交叉验证 + 阈值选择
  compare_routers.py  等预算曲线对比
  make_figures.py     文档图表生成
  build_doc.py        本文档的 PDF 构建
tests/                路由与判分的单元测试（22 项，全绿）
```

这套结构是对"机器学习系统技术债"的一次刻意规避。Sculley 等人指出，ML 系统的维护成本主要来自纠缠（entanglement）、未受控的配置蔓延与隐藏的反馈环[9]。本项目的对应做法是：所有后端共享同一协议（解纠缠）、所有决策共享同一凭证结构与同一份 `Settings`（抑制配置蔓延）、所有路由决策与费用都落盘可查（让反馈环显式化）。

8.2 部署

提供两种部署方式。本地演示用 `make demo` 直接起服务；容器化部署用 `docker compose up`，编排文件同时拉起 Ollama 与应用，模型卷持久化，应用内置健康检查。单 worker 是刻意的——多进程会各自加载一份模型，在 16 GB 内存的机器上会直接打爆。

面向公网的形态换了一种组织方式：多数托管平台只允许一个容器、不保证能常驻第二个服务，因此生产镜像把「应用 + 本地推理」装进同一个镜像——本地推理改用 llama.cpp 提供的 OpenAI 兼容服务，应用侧复用云端那套 Provider，不必为本地单独写客户端；模型权重在构建期下载，运行期离线。当前在线演示部署于 ModelScope 创空间（Docker SDK，2 vCPU / 8 GB），地址见封面。

形态	本地推理	适用场景
本机 venv + Ollama	Ollama 守护进程	开发、录屏
docker compose	Ollama 容器	本地一键复现
单容器生产镜像	llama.cpp server（同容器）	公网演示、评审复现

表 8-1　三种部署形态

部署形态	依赖	适用场景
本机 venv	Python 3.10+、Ollama	开发、录屏演示
Docker Compose	Docker Desktop	公网演示、评审复现

表 8-1　两种部署形态

8.3 复现步骤

```
git clone https://github.com/hanyue0/hybridmind
cd hybridmind
python -m venv .venv && .venv\Scripts\pip install -r requirements.txt
ollama pull qwen2.5:1.5b
copy .env.example .env            # 填入自己的云端密钥（评审请自备）
python scripts/gen_eval_set.py    # 重建 160 条评测集
python -m app.eval.run_eval --mode local
python -m app.eval.run_eval --mode cloud
python scripts/train_router.py    # 训练路由器，输出 AUC 与报告
python scripts/compare_routers.py # 等预算曲线
python -m uvicorn app.web.main:app --port 8000
```

评测集与图表全部由脚本生成，不手填任何数字。密钥只存放在 `.env` 中，该文件已在 `.gitignore` 内；仓库全历史经扫描确认不含任何密钥。

8.4 开发过程留痕

大赛要求作品保留"完整、细粒度的 Git 提交历史"，并明确禁止一次性提交全部功能。本项目的 40 余次提交按模块推进，每次提交对应一个可验收的单元：初始化骨架 → 配置 → 后端抽象 → 规则路由 → 置信度兜底 → 编排 → 评测集 → Web 层 → 测试 → 容器化 → 流式 → 判分修正 → 学习型路由 → 分布外实验。

`docs/ai-logs/` 目录记录了与 AI 协作的关键决策，包括被否决的建议（例如"用大模型判断难度"因成本翻倍被否决）与实测推翻预设的过程（4 tok/s 与 92.5% 这两个数字如何改变了设计）。这些记录构成了原创性与开发过程真实性的证据。

参考文献

1. Wang X, Li Q, Jia W. Cognitive Edge Computing: A Comprehensive Survey on Optimizing Large Models and AI Agents for Pervasive Deployment[J]. arXiv preprint arXiv:2501.03265, 2025.
2. Chen L, Zaharia M, Zou J. FrugalGPT: How to Use Large Language Models While Reducing Cost and Improving Performance[J]. arXiv preprint arXiv:2305.05176, 2023.
3. Shazeer N, Mirhoseini A, Maziarz K, et al. Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer[C]//International Conference on Learning Representations (ICLR). 2017.
4. Varangot-Reille C, Bouvard C, Gourru A, et al. Doing More with Less: A Survey on Routing Strategies for Resource Optimisation in Large Language Model-Based Systems[J]. Journal of Artificial Intelligence Research, 2025. DOI: 10.1613/jair.1.19801. arXiv:2502.00409.
5. Ong I, Almahairi A, Wu V, et al. RouteLLM: Learning to Route LLMs with Preference Data[J]. arXiv preprint arXiv:2406.18665, 2024.
6. Qwen Team. Qwen2.5 Technical Report[J]. arXiv preprint arXiv:2412.15115, 2024.
7. Fu T, Ge Y, You Y, et al. R2R: Efficiently Navigating Divergent Reasoning Paths with Small-Large Model Token Routing[C]//Advances in Neural Information Processing Systems (NeurIPS). 2025. arXiv:2505.21600.
8. Guo C, Pleiss G, Sun Y, et al. On Calibration of Modern Neural Networks[C]//International Conference on Machine Learning (ICML). 2017: 1321-1330.
9. Sculley D, Holt G, Golovin D, et al. Hidden Technical Debt in Machine Learning Systems[C]//Advances in Neural Information Processing Systems (NeurIPS). 2015: 2503-2511.