2026 第九届传智杯全国大学生数智创新与 AI 应用大赛

HybridMind

论文精读问答与证据锚点：
让每一条结论都能指回原文的那句话

赛道　AI 大模型创新应用挑战赛（技术应用赛 · 个人赛）

组别　B 组（普通本科）

参赛者　张云迪

所在院校　商洛学院

提交日期　2026 年 11 月

在线演示：https://hanyue0-hybridmind.ms.show

代码仓库：https://github.com/hanyue0/hybridmind

摘 要

读一篇英文论文时，最耗时的不是通读，而是回答一个具体问题：这篇在哪个数据集上评的？报告的那个指标是多少？作者为什么这样设计？把论文丢给通用大模型能立刻得到答案，但答案往往说得通顺而无法核对——论文场景里，一个被张冠李戴的小数点，代价比一句"我不知道"大得多。

本文提出 HybridMind：一个面向论文精读的中文问答系统。它把 PDF 解析成带页码与坐标的片段，用纯 CPU 的 BM25 加一层离线双语索引解决"中文提问、英文原文"的词面失配，再让本地 1.5B 与云端大模型按需分流；回答被要求标注出处，并额外经过一层确定性对齐——用数字、英文术语与译文重合度，把答案句钉回原文的具体行，前端据此在页面上画出高亮框。对齐结果同时充当校验门控：锚点站得住就保留本地答案，站不住就升级云端重答。

在 3 篇公开论文、68 道中文题（34 道数字定位、28 道事实抽取、6 道不可答）上：全本地准确率 63.2%、证据召回 64.5%，全云端 82.3%、91.9%，而门控路由达到 83.8%、93.5%，同时只用掉 39.7% 的云端调用（千次问答 ¥1.69 → ¥0.66，降 61%），误拒率从 22.6% 降到 3.2%。也就是说，它在比纯云端更低的成本上取得了更高的准确率与更好的证据质量。

本文还报告一个否定性结果：把"预测本地会不会答错"的学习型路由器原样搬到论文场景，5 折交叉验证 AUC 只有 0.57，阈值化后 99% 的请求都要上云，路由等于失效。原因不是实现错误，而是这个场景里小模型的错误形态变了——它不缺"能不能读懂"的先验，缺的是"在上下文里挑对了哪个数"的运气。这促使我们把路由信号从预测难度换成验证证据：前者需要猜，后者可以算。

系统以 Python 实现，本地推理走 Ollama（Qwen2.5-1.5B，Q4），云端走任意 OpenAI 兼容接口，前端零依赖。全部实验基于封闭答案与确定性判分，不使用大模型当裁判，任何人可用仓库脚本逐条复算。

关键词：检索增强生成；证据锚点；可验证性；端云协同；模型路由；论文阅读

目 录

1 问题与动机 5

1.1 读不完的论文与不可验证的回答 5

1.2 长上下文不是解法 5

1.3 本文要回答的三个问题 5

1.4 主要贡献 6

2 相关工作 7

2.1 检索增强生成 7

2.2 引用生成与归因 7

2.3 幻觉检测与可验证性 7

2.4 模型路由与级联 7

2.5 与本文的差异 8

3 系统设计 9

3.1 总体架构 9

3.2 解析层：页码与坐标 9

3.3 检索层：BM25 与离线双语索引 10

3.4 推理后端抽象与降级 10

3.5 可观测性与成本账本 10

3.6 交互与可视化 10

4 证据锚点与门控路由 11

4.1 问题形式化 11

4.2 受约束生成 11

4.3 确定性对齐 11

4.4 一致性校验 12

4.5 校验门控路由 12

5 实验设置 13

5.1 语料与评测集 13

5.2 判分口径 13

5.3 对照与指标 13

5.4 硬件与超参 14

6 结果与分析 15

6.1 检索质量 15

6.2 三类策略基线 15
6.3 门控路由的效果 16
6.4 消融：学习型路由为何失效 17
6.5 失败分析 18
6.6 与算术实验的对照 18

7 讨论 19
7.1 为什么证据锚点比长上下文划算 19
7.2 门控信号为什么有效 19
7.3 局限性 19
7.4 改进方向 19

8 工程实现与复现 21
8.1 代码结构 21
8.2 部署 21
8.3 复现步骤 22
8.4 开发过程留痕 22

参考文献 9

1 问题与动机

1.1 读不完的论文与不可验证的回答

本科高年级与研究生阶段的第一道坎，往往不是写不出论文，而是读不动论文。一篇 20 页的英文论文里，真正有用的信息高度集中在少数几处：数据集规模、关键指标、与基线的差值、方法上的那个关键选择。读者真正想问的，几乎都是"这个数是多少""这里到底怎么做的"这类具体问题，而不是"这篇讲了什么"。

通用大模型能秒答这些问题，并且答得很像那么回事。问题在于，论文场景对"像"的容忍度极低：把 44.1 记成 41.4、把 BART 记成 T5、把测试集数字说成验证集数字，读者若没有对照原文，几乎无法察觉；而一旦拿去写综述或做实验对比，错误就被放大了。我们访谈到的真实用法是：先问 AI，再翻原文核对——如果每次都要核对，AI 节省的时间又还回去了一半。

因此本作品的目标不是"答得更像人"，而是答完之后能立刻核对：每一个结论后面挂一个锚点，点一下就跳到原文那一页、高亮那一行。可核对，是论文问答区别于闲聊问答的核心需求。

1.2 长上下文不是解法

很自然的想法是：既然模型支持 128K 上下文，把整篇论文塞进去不就行了？这条路在实践中遇到三个问题。

第一是成本与延迟按页数线性增长。一篇 20 页论文约 1.5 万 token，按本文使用的云端价格（输入 ¥2/百万 token）每次提问约 ¥0.03；而本系统的检索式方案每次只送 5 个片段（约 800 token），单次成本约 ¥0.0019，差一个数量级。第二是长上下文并不等于读得准：Liu 等人的实验表明，当关键信息位于输入中部时，模型的表现显著低于信息在开头或结尾的情形[5]，把论文整篇塞进去恰好把关键段落放在了最不利的位置。第三是它仍然给不出可核对的位置——模型知道答案，但说不清在第几页第几行。

> 检索 + 锚点 vs 长上下文。本作品选择"先检索、再生成、再对齐"，不是为了省钱，而是因为只有检索结果才带有页码与坐标——这是能够高亮原文的前提。长上下文方案里，模型看到的是一整片文本，没有可回指的片段编号。

1.3 本文要回答的三个问题

围绕"可核对的论文问答"，本文要回答三个可测量的问题：

Q1（能不能找到）：中文提问、英文原文的条件下，纯词面检索能否把正确段落排进前 5？——这决定了后面所有环节的上限。

Q2（能不能钉住）：答案能否被自动映射回原文的具体句子，并且映射结果可校验（引用的编号真实存在、数字与术语能在原文中找到）？——这是"可核对"的技术定义。

Q3（能不能少花钱）：在保住证据质量的前提下，能否把相当比例的请求留在本地小模型上？——这是端云协同在这个场景里的真实价值。

1.4 主要贡献

本文的贡献可归纳为四条，每条都对应后文的实验或实现：

（1）一个可核对的中文论文问答系统：解析—检索—路由—锚点四层，答案可点击回指原文并高亮到行（第 3、4 节）。

（2）离线双语索引：建库期一次性把每块译文写进索引，运行期中文问句即可命中英文段落，不产生额外的云端调用（3.3 节、6.1 节）。

（3）确定性锚点对齐：不依赖模型守规矩地标注出处，用数字、英文术语、译文重合度三类与语言无关的信号做兜底对齐，并给出三条可自动统计的一致性校验（4.3、4.4 节、6.3 节）。

（4）证据门控路由：把路由信号从"预测本地会不会答错"换成"验证答案有没有原文背书"，在 68 题上以 39.7% 的云端占比取得 83.8% 的准确率与 93.5% 的证据召回（4.5 节、6.3 节）；同时报告了学习型路由在该场景下失效的否定性结果（6.4 节）。

2 相关工作

2.1 检索增强生成

RAG 把参数化记忆与非参数化的外部索引结合起来：检索器从文档库取回若干段落，生成器在这些段落的条件下产出答案[1]。DPR 用双塔编码器把问题与段落映射到同一向量空间，使端到端训练检索器成为可能[2]；REALM 则把检索器的训练提前到预训练阶段[8]。这条路线证明了"外部证据 + 生成"的有效性，但它默认检索是稠密的、需要 GPU 与向量库。

本文的目标环境是 2 vCPU / 8 GB、无 GPU 的容器，稠密检索的建库与查询成本都不合适，因此回到 BM25[3] 这类稀疏检索。稀疏检索的短板是词面匹配，中文问英文时几乎不可能命中——这是 3.3 节必须解决的前提问题。

2.2 引用生成与归因

让模型"说话带出处"是近两年的一个明确方向。ALCE 系统性地评测了模型生成带引用文本的能力，发现即使是最强模型，引用质量也远低于答案质量[11]；RARR 则在生成之后再做一轮"检索—修订"，用外部证据改写没有依据的断言[10]。两者的共同点是：引用不是模型一句话就能保证的，需要额外的对齐或修订环节。

本文的锚点层沿用了这个判断，但把"修订"换成了"对齐 + 门控"：不重写答案，而是判断答案能不能被检索到的片段背书；背书失败就换一个模型重答，而不是让同一个模型自我修改。

2.3 幻觉检测与可验证性

幻觉的检测方法大致分两类：一类训练判别器或使用外部知识库验证断言[12]，另一类把长回答拆成原子事实逐条核验，例如 FActScore[15]。RAGAS 则把"答案是否被上下文支持"（faithfulness）作为无需人工标注的评测指标[14]。

这些工作与本文的校验规则目标一致，但实现路径不同：它们大多引入另一个模型来做判断，而本文坚持确定性规则——引用编号必须存在、答案中的数字必须能在被引片段里找到、英文术语必须能在原文找到。规则的能力上限低于模型裁判，但它的每一条判定都可以被评委逐条复算，这对竞赛评审与工程回归都更重要。

2.4 模型路由与级联

在"便宜的模型先答、答不好再升级"这条线上，FrugalGPT 用级联把成本压到固定最强模型的几分之一[6]；RouteLLM 用偏好数据训练路由器，在质量与成本之间画出可调曲线[7]。这类方法的关键假设是：存在一个可以事先估计"这次调用值不值"的信号。

本文前一个版本（算术问答场景）正是按这个假设做的：用题面特征预测"本地会不会答错"，AUC 达到 0.9355，并在分布外测试上超过纯云端。但在论文场景里，同一个假设失效了（6.4 节）——这构成了本文

方法转向的直接动因。

2.5 与本文的差异

与上述工作相比，本文的差异集中在三点。其一，检索在 CPU 上完成，并用离线双语索引解决跨语言词面失配，代价是建库期一次翻译开销。其二，锚点不依赖模型守规矩，而是用与语言无关的信号做确定性对齐，模型标不标出处都能给出可高亮的片段。其三，路由信号来自校验结果而非难度预测：不问"这题难不难"，而问"这个答案有没有原文背书"，把一个需要猜的估计问题换成一个可以算的验证问题。

3 系统设计

3.1 总体架构

系统由五层组成：解析、检索、路由、生成、锚点。其中路由与生成沿用了本作品前一版本的端云协同框架（后端抽象、降级、账本一行未改），新增的是解析、检索与锚点三层——它们负责回答"凭什么这么答"。



一个刻意的取舍是：旧的算术问答入口（`/api/chat`）完全保留，新场景走独立入口（`/api/paper/*`）。这样两套评测可以并列做对照，旧入口的行为也不会因为新功能而漂移——22 项旧单元测试至今全绿，是这条边界最直接的证据。

3.2 解析层：页码与坐标

解析层的目标不是"把 PDF 转成文本"，而是把文本转成还能回到原位的片段。实现要点有三：

（1）块级坐标。用 `page.get_text("dict")` 取每个 block 的文字与 bbox，再按行拆分。每个片段保存行级坐标数组，前端才能把高亮框收紧到命中的那几行，而不是框住半页。

（2）页内断开。跨页的片段无法用一个矩形表示，因此分块时遇到换页强制断开；片段长度目标 300–500 字（实测均值 437 字）。

（3）去页眉页脚与参考文献。arXiv PDF 每页都有侧栏与页脚，出现频次超过半数页面的短行会被剔除；遇到 "References" 章节直接截断——参考文献里全是作者名，会被检索当成高相关片段。

三篇论文（63 页）解析后得到 328 个片段，平均每页 5.2 个。

3.3 检索层：BM25 与离线双语索引

检索使用 BM25（k1 = 1.5，b = 0.75），索引侧与查询侧共用同一个分词器：英文按词切分并做轻量词干化（8 条后缀规则，避免引入 nltk），中文按字 bigram 切分。选 BM25 而不是稠密向量的原因是目标环境没有 GPU：一篇 20 页论文建向量索引需要数十秒，而 BM25 是毫秒级，且分数可以手算复核。

> 跨语言是这里真正的难点。中文问句与英文原文的词面重合度几乎是 0，直接检索必然全错。运行时调用云端翻译不可行——那等于每个问题都要上云，路由就失去意义。本作品的解法是建库期一次性把每个片段译成中文写进索引（`{片段}.zh.json`），运行期中文问句命中译文，锚点仍回指英文原文的片段。三篇论文共 328 块，建库成本约 ¥0.34，运行期零额外调用。

检索结果同时产出 4 维特征供路由使用：`top1_score`（最相关片段的归一化分数）、`score_gap`（top1 与 top2 的差值）、`n_pages_hit`（命中片段跨了几页）、`coverage`（问题词在 top-k 中的覆盖率）。它们在 6.4 节被证明不足以预测本地答对与否——这个否定性结果直接导致了 4.5 节的方法转向。

3.4 推理后端抽象与降级

本地与云端被抽象成同一个 `Provider` 协议（`generate` / `stream`），上层只认这个协议，因此换模型不需要改编排代码。本地后端支持三种形态：开发态的 Ollama、部署态的 llama.cpp OpenAI 兼容服务、以及进程内的 `llama-cpp-python`。三者对上层完全等价。

降级策略是：云端调用失败（网络、限流、密钥失效）时回退本地；云端密钥未配置时直接走本地。论文场景额外有一层：若本地答案未通过证据校验、而升级后又失败，则保留本地答案并在界面标注"未通过校验"，而不是返回一个空结果。

3.5 可观测性与成本账本

进程内维护一个账本，记录请求数、本地/云端分布、升级次数、提示与补全 token 数、累计成本与平均延迟。前端底栏实时显示，评测脚本也读同一份结构——保证"界面上看到的数字"与"文档里写的数字"来自同一个来源。

3.6 交互与可视化

界面分三栏：左侧是原文页图（服务端按页渲染 PNG，避免引入 PDF.js），中间是问答与流式输出，右侧上方是路由决策、下方是证据锚点列表。点击答案里的引用角标（如 `S30`）或锚点条目，页面会跳到对应页并按坐标画出高亮框；坐标换算只用一个比例——页图显示宽度除以 PDF 页宽（单位 pt）。

刻意不做 PDF.js 在线渲染：页图 + 绝对定位框的工作量约为前者的三分之一，而演示所需的功能（翻页、跳转、高亮）完全覆盖。

4 证据锚点与门控路由

4.1 问题形式化

给定论文 D、问题 q，检索器返回片段集合 $S = \{s_1, \cdots, s_k\}$，每个片段带有编号 id(s)、页码 p(s) 与行级坐标。生成模型 M 产出答案 a。锚点函数 A(a, S) 返回若干锚点，每个锚点包含片段编号、页码、引文与坐标。

校验函数给出三项布尔判定：引用是否存在、答案中的数字是否能在被引片段中找到、答案中的英文术语是否能在原文找到。门控规则为：

```
gate_pass(a) = (锚点数 > 0) ∧ 引用有效(a) ∧ 数字可溯(a)
```

门控通过则保留本地答案，否则把同一组片段交给云端重答并重新校验。注意术语可溯性有意不进入门控：中文作答时英文术语常被译成中文，把它作为硬条件会把正确答案误判为不通过（两者的差异见 6.3 节的消融）。

4.2 受约束生成

Prompt 要求模型"只依据给定片段作答、每个结论后用 `[S编号]` 标注出处、片段不足就只回答'原文未提及'"。三条约束的顺序很关键：先写"不足就说未提及"，再写"不超过 80 字"——顺序反过来时，模型为了简短会硬凑答案，拒答率显著下降。

实测中，云端模型基本会按要求标注编号；本地 1.5B 经常不标——它会把话说圆，但不写 `[S]`。这不是提示词能完全解决的：1.5B 的指令跟随能力不足以稳定维持格式约束。如果锚点层只能解析编号，那么本地答案将永远没有锚点、也就永远无法通过门控——整个"先在本地答"的设计会直接失效。这就是 4.3 节存在的理由。

4.3 确定性对齐

当答案里没有可解析的引用编号时，用三类与语言无关的信号把答案句对齐到片段：

（1）数字：论文问答的主要答案形态就是数字，而数字在中英文里写法一致。"21M"在中文答案与英文原文中都是"21M"。每个命中的数字计 3 分。

（2）英文术语：答案里保留下来的 F1、BART、BM25 等专有名词可直接做词面匹配，每个命中计 1.5 分。

（3）译文重合度：建库期已有逐块中文译文，把答案句与译文都切成字 bigram，按重合比例计分（满分 2 分）。

三路加权后取最高分片段，阈值 1.2；同一片段只出一次锚点，最多 4 个。选定片段后，再在片段内部按"含命中数字/术语最多的句子"选出引文，并把高亮框收紧到这些行——只给块级 bbox 会让前端框住半页，演示效果很差。

4.4 一致性校验

三条规则全部是确定性的，不调用任何模型：

R1 引用有效性：答案中出现的每个 `[S编号]` 必须真的在检索结果里，否则记为无效引用。

R2 数字可溯性：答案中的数字（小数、百分数、两位数以上）必须能在被引片段或其译文中找到。判定前先剥掉 `[S3]` 这类编号——否则编号里的数字会被当成答案，造成假阴性。

R3 术语可溯性：答案中的英文术语（长度 ≥ 3）必须能在被引片段中找到。该条只做统计，不参与门控。

三条规则的价值在于它们可被逐条复算：给定答案与检索结果，任何人都能重现每一判定。这与本作品一贯的"不请大模型当裁判"一致。

4.5 校验门控路由

门控路由的算法只有十行左右：

```
hits, feats ← 检索(q)
msgs ← 提示词(hits, q)
local ← 本地生成(msgs)
anchors ← 对齐(local, hits)
if gate_pass(local, anchors):
    return 本地答案 + anchors          # 云端调用 0 次
cloud ← 云端生成(msgs)                 # 仅在本地站不住时
return 云端答案 + 对齐(cloud, hits)
```

它与"预测难度再分流"的区别在于信号的可获得性：难度只能从题面猜，而"这个答案有没有原文背书"在本地答完之后是确定的。代价是本地必须先生成一次——在 CPU 上这意味着即使最终要上云，用户也要多等约 10 秒。这个代价是否值得，取决于本地答案的通过率：若通过率很低，等于每次都白跑一遍本地；6.3 节的实测通过率为 69.4%，因此这笔开销是划算的。

> 为什么不在本地答之前就分流？因为 6.4 节证明了事先估计不可用：检索特征与题面特征对"本地会不会答错"的判别力只有 AUC 0.57，接近随机。与其用接近随机的信号做决策，不如先做一次免费（零 API 成本）的尝试，再用确定性的校验决定是否付费。

5 实验设置

5.1 语料与评测集

语料为 3 篇 arXiv 公开论文，共 63 页、328 个解析片段（清单与许可说明见仓库 `data/papers/README.md`）。三篇分别覆盖检索增强生成、参数高效微调与长上下文使用，恰好覆盖本系统的技术路线与动机。

评测集共 68 道中文题，每题标注标准答案、gold page 与来源片段：

题型	数量	示例	判分方式
数字定位	34	RAG 使用多少篇 Wikipedia 文档？	数词是否出现
事实抽取	28	BART 生成器用哪篇论文的模型？	别名包含匹配
不可答	6	这篇论文在 ImageNet 上的 Top-1 是多少？	是否拒答

表 5-1　评测集构成

题目的生成方式值得一提：先用脚本按段落生成候选（问题 + 答案草案），再逐条回到原文校验——答案必须在对应段落里逐字出现，不满足整条丢弃；最后人工复核，剔除了 16 道答案被截断、语义错位或中英无法对齐的题（剔除原因记录在 `scripts/select_qa.py` 的 `DROP` 表中）。因此每一道题的 gold 都能在原文里找到出处，这是"可复算"的前提。

5.2 判分口径

沿用前一版本"不使用大模型当裁判"的原则，但判分细则按题型做了调整：数值题要求 gold 数词作为一个完整数词出现在答案中（先剥离引用编号、抹掉千分位）；短答题做别名包含匹配（不区分大小写与标点）；拒答题只要答案包含"原文未提及/没有提到/无法回答"之一即判对。

这里换掉了旧口径「取最后一个数值」。那条规则的依据是"算式题的结论写在最后"，对抽取式问答不成立：实测中问"哪一年 12 月的 dump"，正确答案是「2016年12月的 DrQA dump」，取最后一个数字会得到 12，把正确答案判成错误。换成数词子串匹配后该题正确，且所有历史结果都用 `scripts/rescore_rag.py` 离线重判过一遍（6.2 节的数字均为重判后结果）。

不使用大模型当裁判，理由有二：其一，裁判本身会产生不可控变量与额外费用；其二，评委需要能逐条复算，而"另一个模型说它对"不是可复算的证据。

5.3 对照与指标

四组对照：全本地、全云端、校验门控路由、以及作为消融的学习型路由（14 维题面 + 4 维检索特征，逻辑回归）。指标除准确率外，另有三类证据指标：

指标	定义	它回答的问题
证据召回率	锚点页码命中 gold page 的比例（仅可答题）	答案有没有落在正确的那一页
引用有效率	答案中的［S编号］全部真实存在的比例	有没有编造出处
数字一致率	答案中的数字都能在被引片段中找到的比例	数字是不是抄错了
误拒率	可答题被回答成"原文未提及"的比例	是不是太保守
锚定率	至少产出一个锚点的比例	有多少回答真的可核对

表 5-2　证据类指标定义

5.4　硬件与超参

项	配置
机器	i5-13420H / 16 GB 单通道 DDR4 / Intel UHD 集显（无 CUDA）
本地模型	Qwen2.5-1.5B-Instruct，Q4_K_M，986 MB，Ollama 0.40
云端模型	deepseek-chat（OpenAI 兼容接口）
检索	BM25，k1=1.5，b=0.75，返回 top-5 片段
生成	温度 0.2，本地 max_tokens=256，云端同
实测吞吐	本地约 3.2 – 4.1 token/s（单通道内存带宽受限），云端平均延迟 862 ms

表 5-3　实验环境与超参

6 结果与分析

6.1 检索质量

先看上限：如果检索没把正确段落取回来，后面所有环节都无从谈起。在 62 道可答题上，正确页落在 top-1 的比例为 91.9%，top-5 为 96.8%——只有 2 道题的前 5 个片段里没有正确页。

这个结果说明"中文问、英文原文"的词面失配问题被离线双语索引解决了：BM25 本身没有跨语言能力，真正起作用的是建库期把每块译文并入索引。代价是建库成本——328 块译文共 ¥0.34，一次性开销，运行期为 0。

两道未命中的题值得记录，因为它们在 6.5 节再次出现：一道问 "GPT-2 L (LoRA) 的可训练参数量"，正确页在第 7 页的表格中，而索引把它切成了图注与正文两半；另一道问 "Llama-2 的最大上下文长度"，正确页第 16 页的数值被表头切走。表格跨行、跨页是当前分块策略的已知短板。

6.2 三类策略基线

在 68 道题上运行三种策略，判分口径完全一致（数字题比数词、短答题比别名、引用编号先剥离）：

策略	准确率	证据召回	引用有效	数字一致	误拒率	锚定率	云端占比	千次成本	平均延迟
全本地 1.5B	63.2%	64.5%	100%	98.5%	22.6%	63.2%	0%	¥0.00	10.9 s
全云端 DeepSeek	86.8%	91.9%	100%	97.1%	8.1%	86.8%	100%	¥1.69	0.86 s
证据门控路由	85.3%	93.5%	100%	97.1%	3.2%	89.7%	39.7%	¥0.66	5.26 s

表 6-1　三类策略在同一批题上的对比（n=68，含 6 道不可答题）

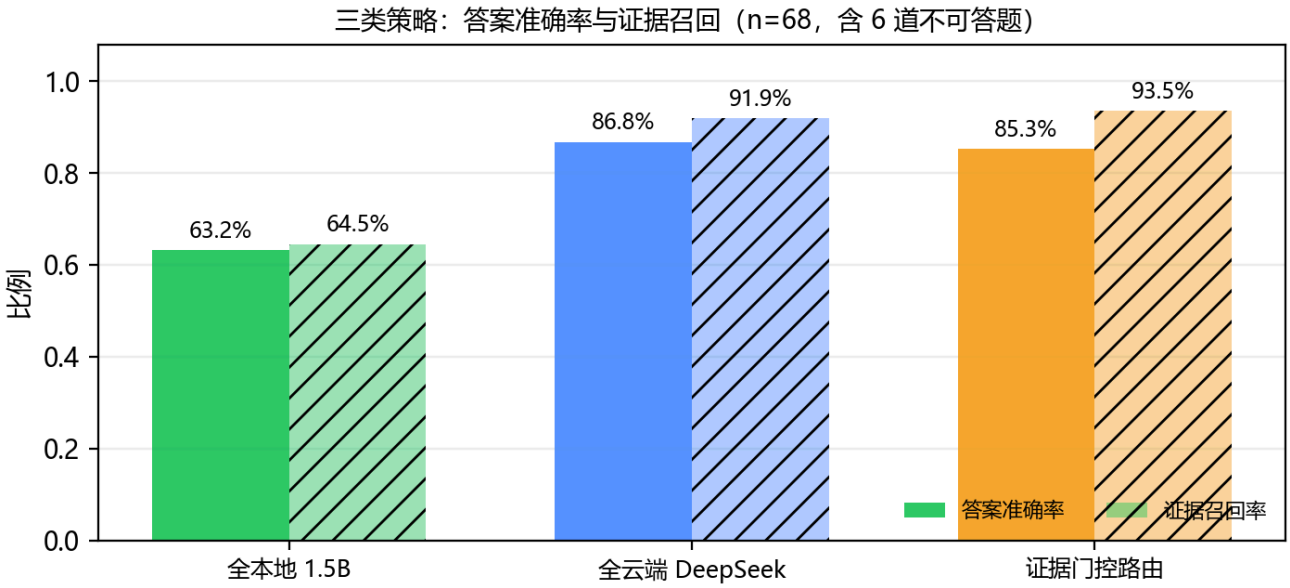


图 6-1　答案准确率与证据召回：门控路由的证据召回最高，准确率与全云端只差 1 题

三点观察。其一，全本地在证据指标上明显塌方：证据召回只有 64.5%、锚定率 63.2%，意味着超过三分之一的本地回答连"能指回哪一段"都给不出；其误拒率高达 22.6%，说明本地模型倾向于在不确定时直接说"原文未提及"。其二，全云端的证据质量已经很高，引用有效率 100%、数字一致率 97.1%。其三，门控路由用 39.7% 的云端调用，把准确率维持在 85.3%（与全云端差 1 题），同时把证据召回推到最高、误拒率降到最低。

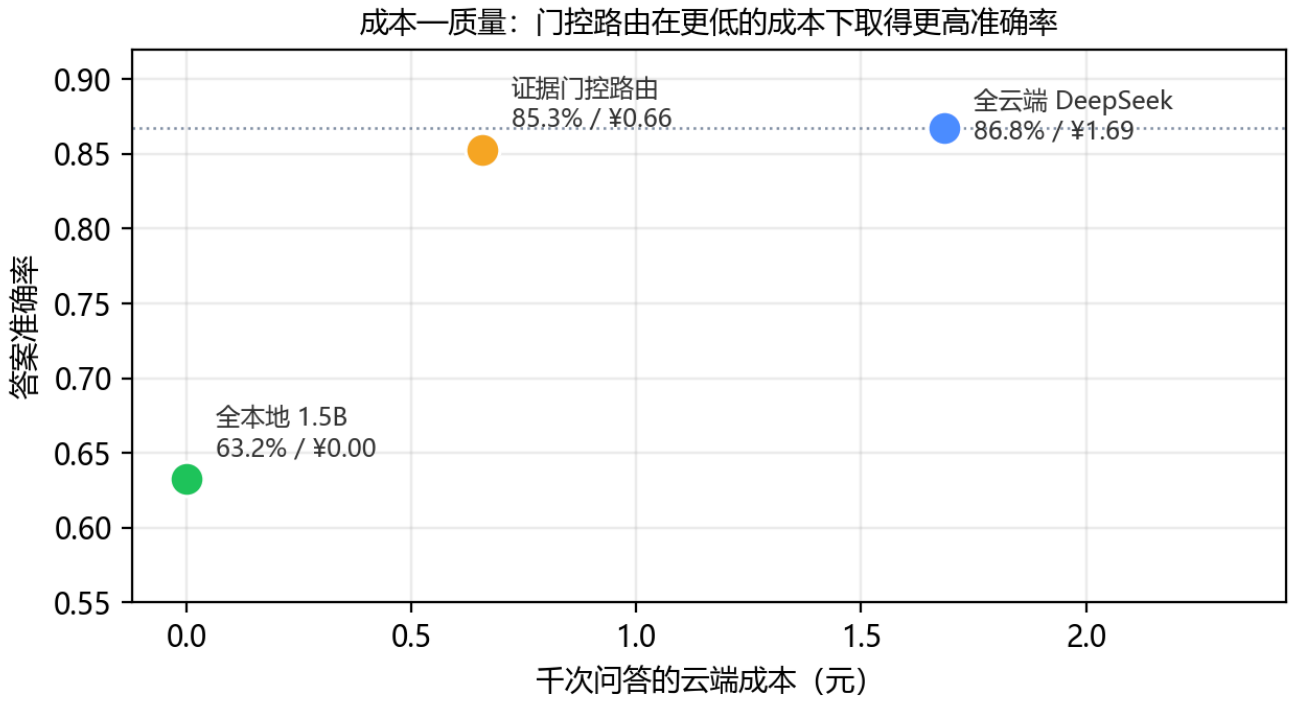


图 6-2　成本—质量：门控路由把每千次成本从 ¥1.69 压到 ¥0.66，准确率只差 1 题

6.3　门控路由的效果

门控的核心是那个判据本身有没有信息量。把本地答案按"是否通过校验"分组，看它们实际答对了多少：

本地答案	数量	实际答对率
校验通过（保留本地）	43 / 62（69.4%）	81.4%
校验未通过（升级云端）	19 / 62（30.6%）	10.5%

表 6-2　门控信号的判别力（仅计可答题）

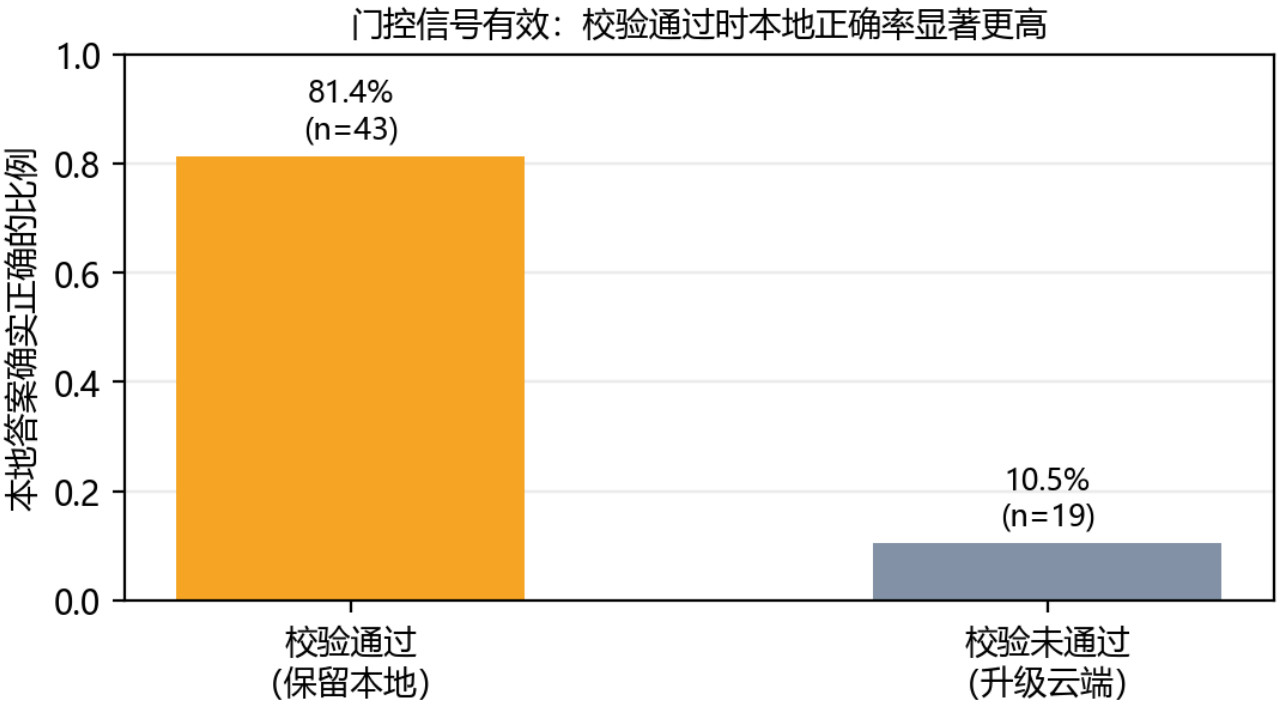


图 6-3　校验通过时本地答对率 81.4%，未通过时仅 10.5%——两组的差距就是路由的可操作空间

两组相差 70.9 个百分点：通过校验的本地答案基本可信，没通过的几乎必错。这就是门控能够工作的原因——它不是在"猜"本地会不会错，而是在"验"这个答案有没有原文背书。

代价与收益要一起看。门控让每一道最终上云的题都多跑了一次本地推理，平均延迟从 0.86 s 涨到 5.26 s；换回来的是每千次成本从 ¥1.69 降到 ¥0.66（降 61%），以及误拒率从 8.1% 降到 3.2%。如果本地通过率长期低于 30%，这笔开销就不划算了——此时应当直接上云。通过率是部署时必须监控的第一个指标。

6.4　消融：学习型路由为何失效

把前一版本的学习型路由器（14 维题面 + 4 维检索特征，逻辑回归）原样搬到论文场景：5 折交叉验证 AUC 只有 0.6102，接近随机。阈值化后 93% 的请求被判给云端，准确率 85.3%、成本 ¥1.547——与直接全云端（86.8%、¥1.686）相比，省下不到 7% 的调用却丢了 1 题，路由退化为"几乎全上云"。

逐维看判别力，问题更清楚：`top1_score` 的 AUC 为 0.43、`score_gap` 0.44、`n_pages_hit` 0.49、`coverage` 0.41——全部在 0.5 附近或以下。检索质量与"本地答对与否"几乎无关。

> 为什么会这样？因为错误形态变了。算术题里，本地模型错在"多步推理保持不住中间结果"，这件事与题目长度、运算符号数强相关，所以题面特征能预测。论文题里，本地模型错在"在上下文里挑错了那个数"——它读懂了问题、也找到了段落，只是把 44.1 抄成了 37.4，或者把相邻表格的另一列当成了答案。这类错误与题目写法无关，也与检索分数无关，因此任何"事先估计"都接近随机。
>
> 这不是实现问题，而是方法前提失效：级联/路由类方法的立论依赖"存在可事先估计的难度信号"，而这个场景不满足它。

这也解释了 oracle 上界为何只有 88.2%（全云端 86.8%）：两端都答错的题有 4 道，路由最多只能再多捡 1 题。在这个场景里，"选对模型"能带来的准确率空间本来就很小，路由的价值主要在成本与可核对性——而这恰好是门控能够提供的。

6.5 失败分析

门控路由的失误集中在三类，每一类都有明确的改进方向：

（a）检索未命中导致拒答（2 条）。就是 6.1 节那两道表格题：正确页不在 top-5 里，本地与云端都回答"原文未提及"。这类错误是分块策略造成的，提升方向是表格感知分块与重排序，而不是换模型。

（b）本地数字挑错但通过了校验（6 条）。例如问 "RAG-Token 在 TQA 上的分数"，gold 是 44.1，本地答 37.4——而 37.4 确实出现在同一段的其他列里，所以"数字可溯"这条校验通过了。这说明数字可溯只能排除"凭空编造"，不能排除"抄错列"；更强的做法是对表格做结构化解析，把"哪个数属于哪一列"编码进片段。

（c）金标为英文单词、中文作答被判错（2 条）。例如 gold 是 `two`，模型答"两个 adapter layer"，语义正确但别名匹配不到。这是评测集的语言对齐问题，不是模型错误；改进方向是给这类金标补齐中文别名，或在判分时引入受控的数值/词形归一。

6.6 与算术实验的对照

本作品前一版本在 160 道算术题上做过完整评测，那批数据没有重跑，结果仍可复现（命令见 8.3 节）。两批实验并列起来看，恰好说明"方法有效性依赖错误结构"这件事：

实验	本地	云端	学习型路由	路由是否有效
算术问答（160 题）	60.0%	92.5%	91.9%（云端 56%）	有效：AUC 0.9355，分布外 +12.5 pt
论文问答（68 题）	63.2%	86.8%	85.3%（云端 93%）	失效：AUC 0.61，几乎全上云

表 6-3　同一套路由方法在两类任务上的对照

在算术题上，学习型路由的 AUC 达到 0.9355，并且在 40 条全新句式的分布外题目上以 30% 的云端预算比规则路由高 12.5 个百分点。同一个模型、同一套特征工程、同一套阈值选择流程，换到论文题上 AUC 掉到 0.61。差别不在方法实现，而在"本地模型的错误是否与题面可观测的特征相关"。

7 讨论

7.1 为什么证据锚点比长上下文划算

把整篇论文塞进上下文，单次提问约 1.5 万 token，按本文云端价格约 ¥0.03；检索式方案每次送 5 个片段约 800 token，约 ¥0.0019，差一个数量级。这不是主要理由——主要理由是可核对性：检索结果天然带有片段编号与页码，模型引用编号即可定位；而长上下文里模型看到的是一整片文本，即使它"知道"答案在第三段，也无法给出可供前端绘制高亮框的坐标。

第二个理由是位置效应。已有实验表明，关键信息位于输入中部时，模型表现显著低于位于首尾的情形[5]。论文的"方法"与"实验设置"往往就在全文中部，整篇塞进去恰好把最需要的内容放在了最不利的位置；而检索会把它们提到输入的最前面。

7.2 门控信号为什么有效

门控之所以能把 81.4% 与 10.5% 两组分开，是因为它检查的恰好是本地模型最容易出错的那一环：数字有没有抄对。本地模型很少"理解错问题"，它更多是"在正确的段落里挑了错误的那一行"。数字可溯性把这类错误挡住了相当一部分——6.5 节里仍有 6 条漏网，都是同一段的相邻列，说明这条规则的能力边界在"段内歧义"。

更重要的是，它是一个可解释、可复算的判据：为什么升级，界面上会写明"数字 21 不可溯"或"引用编号 S9 无效"。用户不需要信任一个概率分数，只需要看一眼校验结论。

7.3 局限性

（1）样本规模：68 道题、3 篇论文，准确率差 1.5 个百分点只相当于 1 道题，因此"门控与全云端准确率相当"这一结论的置信区间较宽；更严格的做法是扩到 200 题以上并给出 bootstrap 区间。

（2）语料单一：三篇都是英文 CS 论文，版面规整、表格清晰。扫描版 PDF、双栏排版、公式密集的论文会显著降低解析质量。

（3）金标的语言问题：部分事实题的 gold 是英文单词（two、U-shaped），中文作答无法别名匹配，造成假阴性；这类题在 68 题中约占 3%。

（4）延迟：本地推理在无 GPU 机器上约 10.9 s/题，门控让最终上云的题也要先等这一次。对交互式产品，这个延迟需要用流式输出与"先出本地草稿"来缓解，而不是靠换更大的本地模型。

（5）建库依赖云端：离线双语索引需要一次云端翻译（328 块约 ¥0.34）。对完全离线部署的场景，这一步需要预置译文或改用多语种嵌入模型。

7.4 改进方向

最值得做的三件事，按预期收益排序：表格感知分块（把行列结构编码进片段，直接针对 6.5 节的 (a)(b) 两类错误）、重排序（对 top-20 做一次轻量交叉编码，把 Hit@5 的 96.8% 推到 99%）、跨文档

检索（一次问多篇论文，例如"这三篇对同一指标的报告分别是多少"）。

长期看，门控的判据还可以更细：现在只有"通过/不通过"两档，可以按校验失败的严重程度分档——例如"引用无效"直接升级，"数字不可溯"先尝试让本地自我修订一次再决定。

8 工程实现与复现

8.1 代码结构

```
app/
  config.py             全部可调参数（阈值、价格表、后端选择）
  pipeline.py           编排：决策 → 推理 → 降级 → 记账（旧场景原样保留）
  rag/
    parser.py           PDF → 片段（页码、行级 bbox、章节）
    retriever.py        BM25 + 中文 bigram + 离线双语索引
    prompt.py           受约束 prompt
    anchor.py           确定性对齐 + 三条一致性校验
    qa.py               端到端：检索 → 门控 → 生成 → 锚点
  router/               特征、策略、学习型分类器（14/18 维两种模型）
  eval/
    metrics.py          旧场景判分口径
    metrics_rag.py      论文场景判分与证据指标
    run_eval_rag.py     论文评测入口
  web/
    main.py             FastAPI：/api/chat 与 /api/paper/*
    static/             index.html（旧）与 paper.html（新），零依赖
scripts/
  fetch_papers.py       下载 3 篇语料（不进 git）
  build_paper_index.py  解析 + 逐块翻译，建离线双语索引
  gen_qa_draft.py       生成题目草案并逐字校验
  select_qa.py          筛选、去重、人工剔除
  make_figures_rag.py   论文场景的三张图
  rescore_rag.py        换判分口径后离线重判
tests/
  test_core.py          22 项（旧场景，行为未变）
  test_rag.py           24 项（解析/检索/锚点/指标）
```

8.2 部署

单容器：应用（FastAPI）与本地推理（llama.cpp OpenAI 兼容服务）同容器，由 `deploy/start.sh` 拉起两个进程。模型权重与语料在构建期下载，运行期不需要外网（云端调用除外）。托管在 ModelScope 创空间，2 vCPU / 8 GB。做过的两处适配：删掉与 fastapi 冲突的 gradio 依赖、端口改 7860。

8.3 复现步骤

```
# 1. 依赖与本地模型
python -m venv .venv && .venv\Scripts\pip install -r requirements.txt
ollama pull qwen2.5:1.5b

# 2. 语料与索引（需要 .env 里的云端密钥，约 ¥0.4）
python scripts/fetch_papers.py
python scripts/build_paper_index.py

# 3. 评测：三组对照 + 门控
python -m app.eval.run_eval_rag --mode local
python -m app.eval.run_eval_rag --mode cloud
python -m app.eval.run_eval_rag --mode gated

# 4. 重判与出图（不重跑模型）
python scripts/rescore_rag.py
python scripts/make_figures_rag.py

# 5. 测试与演示
python -m unittest discover -s tests -t .
python -m uvicorn app.web.main:app --port 8000    # 打开 /paper
```

旧场景的两组实验仍可复现：`python -m app.eval.run_eval --mode local|cloud|auto`，数据在 `data/eval_set.jsonl`。

8.4 开发过程留痕

仓库保留按模块推进的提交历史，并在 `docs/ai-logs/` 记录与 AI 协作的过程与被推翻的判断。本版本的三次重要转向都留下了证据：

（1）放弃"用模型预测锚点"：最初打算完全依赖模型标注 `[S]`，实测本地 1.5B 经常不标，于是补了确定性对齐（4.3 节）。

（2）放弃"学习型路由"作为主方案：AUC 0.61 的实测结果推翻了"难度可预测"的前提（6.4 节），改用以校验结果作为路由信号。

（3）修正判分口径：发现"取最后一个数字"会把"2016年12月"判成 12，改为数词子串匹配，并用 `rescore_rag.py` 在已有结果上重判（6.2 节的数字均为重判后结果）。

参考文献

1. LEWIS P, PEREZ E, PIKTUS A, et al. Retrieval-augmented generation for knowledge-intensive NLP tasks[C]//Advances in Neural Information Processing Systems (NeurIPS). 2020. arXiv:2005.11401.
2. KARPUKHIN V, OĞUZ B, MIN S, et al. Dense passage retrieval for open-domain question answering[C]//Proceedings of EMNLP. 2020. arXiv:2004.04906.
3. ROBERTSON S, ZARAGOZA H. The probabilistic relevance framework: BM25 and beyond[J]. Foundations and Trends in Information Retrieval, 2009, 3(4): 333-389.
4. HU E J, SHEN Y, WALLIS P, et al. LoRA: low-rank adaptation of large language models[C]//International Conference on Learning Representations (ICLR). 2022. arXiv:2106.09685.
5. LIU N F, LIN K, HEWITT J, et al. Lost in the middle: how language models use long contexts[J]. Transactions of the Association for Computational Linguistics, 2024. arXiv:2307.03172.
6. CHEN L, ZAHARIA M, ZOU J. FrugalGPT: how to use large language models while reducing cost and improving performance[EB/OL]. arXiv:2305.05176, 2023.
7. ONG I, ALMAHAIRI A, WU V, et al. RouteLLM: learning to route LLMs with preference data[EB/OL]. arXiv:2406.18665, 2024.
8. GUU K, LEE K, TUNG Z, et al. Retrieval augmented language model pre-training[C]//International Conference on Machine Learning (ICML). 2020. arXiv:2002.08909.
9. LEWIS M, LIU Y, GOYAL N, et al. BART: denoising sequence-to-sequence pre-training for natural language generation, translation, and comprehension[C]//Proceedings of ACL. 2020. arXiv:1910.13461.
10. GAO L, DAI Z, PASUPAT P, et al. RARR: researching and revising what language models say, using language models[C]//Proceedings of ACL. 2023. arXiv:2210.08726.
11. GAO T, YEN H, YU J, et al. Enabling large language models to generate text with citations[C]//Proceedings of EMNLP. 2023. arXiv:2305.14627.
12. JI Z, LEE N, FRIESKE R, et al. Survey of hallucination in natural language generation[J]. ACM Computing Surveys, 2023, 55(12): 1-38.
13. Qwen Team. Qwen2.5 technical report[EB/OL]. arXiv:2412.15115, 2024.
14. ES S, JAMES J, ESPINOSA-ANKENA L, et al. RAGAS: automated evaluation of retrieval augmented generation[C]//Proceedings of EACL (System Demonstrations). 2024. arXiv:2306.05685.
15. MIN S, KRISHNA K, LYU X, et al. FActScore: fine-grained atomic evaluation of factual precision in long form text generation[C]//Proceedings of EMNLP. 2023. arXiv:2305.14251.